

STUDI LITERATUR REVIEW (SLR): PERKEMBANGAN DAN IMPLEMENTASI TEKNOLOGI QUERY OPTIMIZATION PADA SISTEM BASIS DATA TERDISTRIBUSI

20230801456 – Muhammad Ridho Faturahman | Ujian Tengah Semester
CIE721 – Sistem Basis Data Terdistribusi | Teknik Informatika – Universitas Esa Unggul

1. PENDAHULUAN

Distributed database sudah menjadi tulang punggung hampir semua layanan berbasis cloud saat ini. Ketika satu server tidak lagi cukup untuk menangani volume data yang terus tumbuh, sistem terdistribusi menjadi solusi yang logis. Tapi ada konsekuensi yang tidak bisa dihindari: kompleksitas eksekusi query meningkat drastis. Di lingkungan terdistribusi, optimizer tidak hanya perlu memikirkan join ordering dan index selection, tapi juga biaya transfer data antar node, heterogenitas format dari berbagai sumber, dan latensi jaringan yang tidak pasti.

Optimizer tradisional yang mengandalkan statistik statis dan cost model sederhana sering gagal memberikan rencana eksekusi yang efisien dalam kondisi seperti ini (Marcus et al., 2021; Yang et al., 2022). Penelitian beberapa tahun terakhir mulai mengeksplorasi pendekatan berbasis machine learning – dari reinforcement learning hingga hybrid approach – sebagai alternatif atau pelengkap optimizer konvensional (Anneser et al., 2023; Chen et al., 2023; Giannakouris & Trummer, 2022). Dari sini muncul dua pertanyaan yang coba dijawab tulisan ini:

RQ1: Metode query optimization apa saja yang berkembang dalam konteks distributed database (2021–2023), dan bagaimana perbandingan performa antar metode tersebut?

RQ2: Apa saja keterbatasan dan research gap yang masih terbuka dari penelitian-penelitian yang sudah ada?

2. METODE PENCARIAN LITERATUR

Pencarian dilakukan pada IEEE Xplore, ACM Digital Library, Springer Link, dan Google Scholar. Untuk prosiding konferensi, diprioritaskan VLDB, SIGMOD, dan ICDE karena ketiganya merupakan venue tier-1 untuk riset database. String pencarian utama yang digunakan adalah:

("query optimization" OR "query planning") AND ("distributed database" OR "distributed query processing" OR "federated query") AND ("machine learning" OR "reinforcement learning" OR "neural network" OR "cost model")

Artikel dimasukkan jika: diterbitkan 2021–2023, membahas teknik optimasi query dalam sistem terdistribusi, tersedia dalam bahasa Inggris, dan dipublikasikan di jurnal/prosiding terindeks. Artikel dieksklusi jika hanya fokus pada single-node database, merupakan survei murni tanpa kontribusi metode, atau hanya tersedia sebagai preprint tanpa proses peer review.

3. MATRIKS SINTESIS LITERATUR

Tabel berikut merangkum enam artikel yang dianalisis dalam studi ini:

Penulis & Tahun	Metode / Algoritma	Hasil Utama	Keterbatasan / Gap
(Yang et al., 2022)	Balsa — deep RL query optimizer tanpa expert demonstrations	Menyamai performa 2 expert optimizer di Join Order Benchmark dalam 2 jam; unggul 2.8x setelah beberapa jam berikutnya	Masih membutuhkan simulator awal; belum diuji di lingkungan distributed multi-node
(Marcus et al., 2021)	Bao — bandit optimizer + tree convolution	Unggul di 46/70 query TPC-H vs PostgreSQL default; latensi tail berkurang	Bergantung pada query history; sulit generalize ke skema baru
(Trummer et al., 2021)	SkinnerDB — adaptive join ordering (RL-based)	Tidak perlu statistik tabel; robust terhadap estimasi kardinalitas salah	Overhead tinggi pada query sederhana; kurang skalabel di join >10 tabel
(Chen et al., 2023)	LEON — hybrid MCTS + cost model kalibrasi ML	Lebih stabil dari pure RL; planning time kompetitif dibanding PostgreSQL native	Evaluasi terbatas pada benchmark TPC; belum diuji workload produksi nyata
(Giannakouris & Trummer, 2022)	ML-based federated query optimizer di atas Spark SQL	Eksekusi query hingga 7.5x lebih cepat dibanding Spark SQL vanilla pada federated workload	Masih prototipe; evaluasi terbatas; skalabilitas di cluster besar belum diuji
(Anneser et al., 2023)	AutoSteer — bandit optimizer + automated hint-set discovery	Berhasil diuji di 5 DB engine; generalize ke berbagai workload termasuk produksi Meta	Masih bergantung pada query history; performa turun pada workload yang sangat bervariasi

4. PEMBAHASAN DAN RESEARCH GAP

4.1 Tren Penelitian

Dari literatur yang terkumpul, terlihat jelas bahwa penelitian query optimization untuk distributed database bergerak ke arah data-driven approach. Pendekatan berbasis RL mendapat perhatian paling besar, terutama untuk masalah join ordering — ruang pencariannya tumbuh eksponensial seiring bertambahnya tabel, dan RL bisa mempelajari kebijakan yang baik tanpa harus mengevaluasi semua kemungkinan (Trummer et al., 2021; Yang et al., 2022).

Di sisi lain, ada juga arah yang lebih pragmatis: hybrid approach yang menggabungkan cost-based optimizer dengan komponen ML. Ini terlihat dari LEON (Chen et al., 2023) yang tidak membuang cost model yang sudah ada, melainkan menggunakannya sebagai panduan sambil membiarkan MCTS mengeksplorasi ruang pencarian lebih luas. AutoSteer (Anneser et al., 2023) mengambil pendekatan serupa dengan memperluas Bao menggunakan hint-set discovery otomatis, sehingga bisa bekerja di berbagai SQL engine tanpa modifikasi internal.

4.2 Perbandingan Metode dan Research Gap

Balsa (Yang et al., 2022) menunjukkan bahwa optimizer berbasis RL bisa belajar dari nol tanpa perlu demonstrasi dari expert optimizer — sebuah langkah maju yang cukup signifikan. Di sisi lain, Bao (Marcus et al., 2021) lebih konservatif dengan hanya memberikan 'hint' ke optimizer yang sudah ada, hasilnya lebih stabil di produksi tapi masih bergantung pada query history yang memadai. SkinnerDB (Trummer et al., 2021) mengambil pendekatan yang sama sekali berbeda: belajar join order secara adaptif selama eksekusi query berlangsung, tanpa statistik tabel sama sekali.

Untuk konteks federated/multi-engine, Giannakouris & Trummer (2022) paling relevan karena secara eksplisit merancang optimizer untuk lingkungan di mana data tersebar di berbagai engine yang berbeda. Sistem prototipe mereka di atas Spark SQL mencapai speedup hingga 7.5x — angka yang cukup menjanjikan meski evaluasinya masih terbatas. AutoSteer (Anneser et al., 2023) melengkapi lanskap ini dengan generalisasi yang lebih luas, sudah diuji di lima engine berbeda termasuk workload produksi dari Meta.

Gap yang paling konsisten terlihat adalah kurangnya validasi pada workload produksi nyata — hampir semua penelitian masih bergantung pada TPC benchmark (Chen et al., 2023; Marcus et al., 2021; Yang et al., 2022). Skalabilitas di cluster besar juga belum pernah dievaluasi secara serius. Yang paling underexplored adalah penanganan kegagalan node secara real-time: node failure adalah kondisi normal di sistem terdistribusi, tapi hampir tidak ada penelitian yang membahas bagaimana optimizer harus menyesuaikan rencana eksekusi ketika satu node mati di tengah query yang sedang berjalan (Giannakouris & Trummer, 2022; Trummer et al., 2021).

5. KESIMPULAN

Menjawab RQ1: Penelitian query optimization untuk distributed database (2021–2023) didominasi dua aliran — pure learning-based seperti Balsa (Yang et al., 2022), Bao (Marcus et al., 2021), dan SkinnerDB (Trummer et al., 2021), serta hybrid approach seperti

LEON (Chen et al., 2023) dan AutoSteer (Anneser et al., 2023). Untuk konteks federated/multi-engine, Giannakouris & Trummer (2022) menunjukkan arah yang paling relevan. Metode hybrid lebih stabil untuk produksi, sementara pure learning berpotensi menghasilkan peningkatan performa lebih besar dengan trade-off yang lebih banyak.

Menjawab RQ2: Research gap yang paling signifikan meliputi kurangnya validasi pada workload produksi nyata (Marcus et al., 2021; Yang et al., 2022), evaluasi skalabilitas di cluster besar yang masih terbatas, dan penanganan kegagalan node yang hampir tidak pernah dibahas secara eksplisit (Giannakouris & Trummer, 2022). Untuk penelitian berikutnya, disarankan fokus pada optimizer yang adaptif terhadap kegagalan node secara real-time dan studi empiris menggunakan workload produksi dari platform cloud nyata.

DAFTAR PUSTAKA

- Anneser, C., Tatbul, N., Cohen, D., Xu, Z., Pandian, P., Laptev, N., & Marcus, R. (2023). AutoSteer: Learned Query Optimization for Any SQL Database. *Proceedings of the VLDB Endowment*, 16(12), 3515–3527. <https://doi.org/10.14778/3611540.3611544>
- Chen, X., Chen, H., Liang, Z., Liu, S., Wang, J., Zeng, K., Su, H., & Zheng, K. (2023). LEON: A New Framework for ML-Aided Query Optimization. *Proceedings of the VLDB Endowment*, 16(9), 2261–2273. <https://doi.org/10.14778/3598581.3598597>
- Giannakouris, V., & Trummer, I. (2022). Building Learned Federated Query Optimizers. *CEUR Workshop Proceedings: VLDB 2022 PhD Workshop*, 3186. https://ceur-ws.org/Vol-3186/paper_5.pdf
- Marcus, R., Negi, P., Mao, H., Tatbul, N., Alizadeh, M., & Kraska, T. (2021). Bao: Making Learned Query Optimization Practical. *Proceedings of the ACM International Conference on Management of Data (SIGMOD)*, 1275–1288. <https://doi.org/10.1145/3448016.3452838>
- Trummer, I., Wang, J., Wei, Z., Maram, D., Moseley, S., Jo, S., Antonakakis, J., & Rayabhari, A. (2021). SkinnerDB: Regret-Bounded Query Evaluation via Reinforcement Learning. *ACM Transactions on Database Systems*, 46(3), 1–45. <https://doi.org/10.1145/3464389>
- Yang, Z., Chiang, W.-L., Luan, S., Mittal, G., Luo, M., & Stoica, I. (2022). Balsa: Learning a Query Optimizer Without Expert Demonstrations. *Proceedings of the ACM International Conference on Management of Data (SIGMOD)*, 931–944. <https://doi.org/10.1145/3514221.3517885>